Теория информации и кодирования
Домашнее задание №1

Гудзь Родион

Вариант 7

Параметры варианта

$$k = 4, \quad M = 3, \quad L = 5, \quad d = 2, \quad q = 7, \quad \varepsilon = 10^{-3}$$

Алфавит $A = \{0, 1, 2, 3\}$

Задача 1.1

	0	1	2	3
m_1	$1/2$	$1/4$	$1/8$	$1/8$
m_2	$1/4$	$1/4$	$1/4$	$1/4$
m_3	$1/8$	$1/8$	$1/4$	$1/2$

	m_1	m_2	m_3
s_1	1	0	0
s_2	0	1	0
s_3	0	0	1
s_4	$1/2$	$1/2$	0
s_5	0	$1/2$	$1/2$

Распределения по позициям периода:

j	0	1	2	3
0	$1/2$	$1/4$	$1/8$	$1/8$
1	$1/4$	$1/4$	$1/4$	$1/4$
2	$1/8$	$1/8$	$1/4$	$1/2$
3	$3/8$	$1/4$	$3/16$	$3/16$
4	$3/16$	$3/16$	$1/4$	$3/8$

Для блока 01:

$$P_1 = \frac{1}{2} \cdot \frac{1}{4} = \frac{1}{8}, \qquad P_{\text{per}} = \frac{1}{5}\left(\frac{1}{8} + \frac{1}{16} + \frac{1}{64} + \frac{3}{32} + \frac{9}{64}\right) = \frac{39}{640}$$

N	$\widehat{P}_N$	$\lvert\widehat{P}_N - P_1\rvert$	$\lvert\widehat{P}_N - P_{\text{per}}\rvert$
10^2	0.050505	0.074495	0.010432
10^3	0.073073	0.051927	0.012136
10^4	0.059606	0.065394	0.001332
10^5	0.061851	0.063149	0.000913
10^6	0.060635	0.064365	0.000302

$$\widehat{P}_N \longrightarrow P_{\text{per}}$$

Окно проходит позиции периода равномерно, поэтому усредняется вероятность по позициям, а не только вероятность на первом такте

Расширенный формат

Поле `kind` задаёт тип источника:

`memoryless`, `periodic`, `markov`, `mixture`

Общая форма:

```
{"kind": T, "alphabet": A, ...}
```

Тип	Данные	Свойство
memoryless	distribution	стационарный, эргодический
periodic	distributions	нестационарный
markov	memory=2, initial, transitions	стационарный, эргодический
mixture	components с весами	стационарный, неэргодический

Примеры на A:

```
{"kind":"memoryless", "distribution":{"0":"1/2","1":"1/4","2":"1/8","3":"1/8"}}
{"kind":"periodic", "distributions":[P1,P2]}
{"kind":"markov", "memory":2, "initial":uniform(A^2), "transitions":uniform(A)}
{"kind":"mixture", "components":[{"weight":"1/2","source":S1},
                        {"weight":"1/2","source":S2}]}
```

Здесь P_1, P_2 различны, в марковской модели все переходы положительны, в смеси компонент выбирается один раз. Полная грамматика и JSON-файлы приведены в `SOURCE_FORMAT.md`

Задача 1.2

Для режима 1 использовано $P = (1/2, 1/4, 1/8, 1/8)$:

$$H(X) = -\sum p_i \log_2 p_i = \frac{7}{4} = 1.75 \text{ бит}$$

Для типа $\nu = (\nu_0, \ldots, \nu_{k-1})$:

$$p(\nu) = \prod_i p_i^{\nu_i}, \qquad C(\nu) = \frac{n!}{\prod_i \nu_i!}, \qquad \#\text{типов} = \binom{n+k-1}{k-1}$$

Типы сортируются по $p(\nu)$, затем выбираются q^ℓ слов с учётом $C(\nu)$, где

$$\ell = \left\lfloor \frac{nR}{\log_2 q} \right\rfloor, \qquad P_e(n) = 1 - \sum_\nu t_\nu p(\nu)$$

Время при $k = 4$, $n_{\max} = 50$, $R = 2$: 1.63 с

n	$\ell(n)$	$P_e(n)$
1	0	0.500000
2	1	0.250000
3	2	0.042969
5	3	0.176270
10	7	0.004183
17	12	0.000563
20	14	0.001767
30	21	0.000708
40	28	0.000297
50	35	0.000130

$$n_{\min} = 17, \qquad P_e(17) = \frac{1237155295}{2199023255552} = 0.000562593093036412 \le \varepsilon$$

При $R = 1.5 < H(X)$: $P_e(1) = 0.5$, $P_e(10) = 0.613228$, $P_e(20) = 0.808131$, $P_e(50) = 0.938759$. Следовательно, для больших n условие гарантируется только при $R > H(X)$

Задача 1.3

Сигнатура контейнера: `ZMH1`. Заголовок:

поле	размер
версия	1 байт
размер исходных данных	8 байт
CRC32	4 байта
число символов	2 байта
символ и длина кода	2 байта на символ

$$B_h = 19 + 2m$$

Хранятся длины канонического кода Хаффмана. Неполный последний байт дополняется нулями, размер исходных данных отделяет заполнение

Файл	H	$\bar{\ell}$	B_h	B_d	B_{out}	K
Русский текст	3.6711	3.7233	81	96	177	0.8592
Английский текст	2.4047	2.5000	31	6	37	2.0556
PNG	7.9663	7.9763	531	223688	224219	0.9994
Повторяющийся байт	0	1.0000	21	13	34	0.3400
Пустой файл	0	0	19	0	19	–

$$K = \frac{B_h + B_d}{B_{in}}, \qquad 21 + \left\lceil \frac{n}{8} \right\rceil \le n \iff n \ge 24$$

Малые текстовые файлы увеличиваются из-за заголовка, PNG почти не сжимается из-за предварительного сжатия

Диагностики:

случай	сообщение
чужой формат	
обрыв	
ошибка модели или CRC	

Проектные решения

1. Расширение: одно поле `kind`; исходный формат преобразуется в `periodic`; выбрано для совместимости
2. Арифметика: строки вероятностей и `Fraction`; выбрано вместо float для точного сравнения
3. 1.2: перебор типов вместо k^n слов; сложность $O(n^{k-1})$
4. zmh: CRC32, размер данных и канонические длины; выбран компактный заголовок
5. Повреждения: структурные проверки и CRC32; так различаются обрыв, чужой формат и повреждение

Журнал неудач

Сначала использовался полный перебор слов в задаче 1.2, но он не проходил ограничение времени. Затем был заменён перебором типов. В первом варианте заголовка хранились частоты, после чего выбраны канонические длины, что уменьшило размер заголовка. Для пустого и односимвольного файлов добавлены отдельные случаи